

PENERAPAN DECISION TREE PADA DATASET TITANIC

Bagian 1 – Pemahaman Konsep (Teori)

Perkembangan Machine Learning memungkinkan analisis data historis untuk memprediksi kejadian di masa depan. Salah satu algoritma yang populer dan mudah dipahami adalah Decision Tree.

Pada studi kasus ini, Decision Tree digunakan untuk memprediksi apakah penumpang Titanic selamat atau tidak berdasarkan fitur seperti usia, jenis kelamin, kelas penumpang, dan tarif.

Apa yang dimaksud dengan Decision Tree?

Decision Tree adalah algoritma supervised learning yang digunakan untuk klasifikasi dan regresi dengan membentuk struktur pohon keputusan. Setiap keputusan dibuat berdasarkan kondisi tertentu hingga mencapai hasil akhir.

Konsep pada Decision Tree

1. Node
Titik pada pohon yang merepresentasikan pengujian suatu atribut.
2. Root
Node paling atas yang menjadi awal proses pengambilan keputusan.
3. Leaf
Node akhir yang berisi hasil prediksi (kelas atau nilai).
4. Splitting
Proses membagi data ke dalam beberapa cabang berdasarkan nilai atribut tertentu untuk memaksimalkan pemisahan kelas.
5. Pruning
Proses memangkas cabang pohon untuk mengurangi kompleksitas dan mencegah overfitting.

| Aspek | Decision Tree | Random Forest | Gradient Boosting |
|--------------|---------------|---------------|-----------------------|
| Jumlah Model | 1 pohon | Banyak pohon | Banyak pohon bertahap |
| Teknik | Single model | Bagging | Boosting |
| Overfitting | Tinggi | Lebih rendah | Sangat rendah |
| Interpretasi | Mudah | Sulit | Sulit |
| Akurasi | Sedang | Tinggi | Sangat tinggi |

Kelebihan dan Kekurangan Tree-Based Methods

Kelebihan:

- Mudah dipahami dan diinterpretasikan
- Tidak memerlukan normalisasi data
- Dapat menangani data numerik dan kategorik
- Cocok untuk analisis awal (baseline model)

Kekurangan:

- Rentan terhadap overfitting
- Sensitif terhadap perubahan kecil pada data
- Kurang stabil dibanding metode ensemble

Bagian 2 – Implementasi Model

1. Load dan Eksplorasi Dataset

```
● ● ●  
1 import pandas as pd  
2 import seaborn as sns  
3  
4 # Load dataset  
5 df = sns.load_dataset('titanic')  
6  
7 print(df.head())  
8 print(df.info())  
9 print(df.isnull().sum())
```

Hasil EDA:

- Terdapat missing value pada kolom age, deck, dan embark_town
- Target variabel: survived

2. Preprocessing Data

```
● ● ●  
1 from sklearn.model_selection import train_test_split  
2  
3 X_train, X_test, y_train, y_test = train_test_split(  
4     X, y, test_size=0.2, random_state=42  
5 )
```

3. Split Data Training dan Testing

```
● ● ●  
1 from sklearn.preprocessing import LabelEncoder  
2  
3 # Mengisi missing value  
4 df['age'].fillna(df['age'].median(), inplace=True)  
5 df['embarked'].fillna(df['embarked'].mode()[0], inplace=True)  
6  
7 # Encoding data kategorik  
8 encoder = LabelEncoder()  
9 df['sex'] = encoder.fit_transform(df['sex'])  
10 df['embarked'] = encoder.fit_transform(df['embarked'])  
11  
12 # Seleksi fitur  
13 X = df[['pclass', 'sex', 'age', 'fare', 'embarked']]  
14 y = df['survived']
```

4. Membangun Model Decision Tree

```
● ● ●  
1 from sklearn.tree import plot_tree  
2 import matplotlib.pyplot as plt  
3  
4 plt.figure(figsize=(20,10))  
5 plot_tree(  
6     model,  
7     feature_names=X.columns,  
8     class_names=['Not Survived', 'Survived'],  
9     filled=True  
10 )  
11 plt.show()
```


Evaluasi Model

```
● ● ●  
1 from sklearn.metrics import accuracy_score, classification_report  
2  
3 y_pred = model.predict(X_test)  
4  
5 print("Accuracy:", accuracy_score(y_test, y_pred))  
6 print(classification_report(y_test, y_pred))
```

Visualisasi Pohon Keputusan

```
● ● ●  
1 from sklearn.tree import DecisionTreeClassifier  
2  
3 model = DecisionTreeClassifier(  
4     criterion='entropy',  
5     max_depth=4,  
6     random_state=42  
7 )  
8  
9 model.fit(X_train, y_train)
```

Output



Bagian 3 – Analisis dan Kesimpulan

Model Terbaik

Decision Tree dengan:

- criterion = entropy
- max_depth = 4

Memberikan keseimbangan antara akurasi dan kompleksitas model.

Faktor yang Mempengaruhi Performa Model

- Kedalaman pohon (max_depth)
- Kualitas preprocessing data
- Pemilihan fitur
- Ketidakseimbangan kelas

Kelebihan Tree-Based Methods pada Studi Kasus

- Mudah menjelaskan faktor keselamatan penumpang
- Memberikan aturan keputusan yang jelas
- Cocok untuk data tabular seperti Titanic

Kesimpulan Akhir

Decision Tree mampu memprediksi survival penumpang Titanic dengan performa yang baik dan interpretasi yang jelas. Dengan pengaturan parameter yang tepat, algoritma ini efektif digunakan sebagai model dasar sebelum beralih ke metode ensemble seperti Random Forest atau Gradient Boosting.

